基于深度学习的 5G 大规模 MIMO 信息压缩、量化与多用户优化

摘要

本文针对 5G 大规模 MIMO 系统中信道状态信息(CSI)反馈开销巨大的问题，提出了一套完整的高效反馈技术解决方案。研究包含三个核心子任务：CSI 压缩与重建模型设计、量化与噪声鲁棒性分析、多用户联合反馈策略。

针对 CSI 压缩与重建模型设计问题，基于特征学习和非线性映射理论，设计了多尺度自适应压缩模型。该模型采用分层编码器结构捕获 CSI 的多尺度空间特征，引入多头注意力机制强化关键路径信息，通过残差连接增强重建质量。实验结果表明，在 1/4、1/8、1/16 压缩比下分别实现了 0.0833、0.2327、0.2396 的 NMSE 性能，余弦相似度分别达到 0.9744、0.9818、0.9689，模型参数量仅为 15,826 个，满足 5G NR 系统对反馈精度和复杂度的双重要求。

针对量化与噪声鲁棒性问题，基于信息论和鲁棒优化理论，建立了完整的噪声鲁棒训练框架。提出了量化感知训练方法，通过直通估计器实现可微分的量化过程；设计了对抗训练策略，在 CSI 样本中注入不同水平的加性高斯白噪声；引入自适应比特分配机制，根据信道质量动态调整量化精度。实验验证表明，模型在 0-25dB SNR 范围内均能保持稳定性能，NMSE 从 1.25（0dB）逐渐降低到 0.78（25dB），自适应量化策略相比固定比特方案有效降低了系统反馈开销。

针对多用户联合反馈优化问题，基于空间相关性和分布式压缩理论，构建了协同反馈架构。利用用户间的信道空间相关性，设计了共享-个性化分层压缩机制；通过动态用户聚类算法实现最优分组；采用差异化量化策略优化比特资源分配。性能评估显示，相比传统独立反馈方案，所提联合反馈策略平均降低系统总反馈开销约 16%，同时保持了各用户重建质量的一致性，NMSE 方差显著降低，体现了良好的用户公平性。

通过全面的系统性能评估，验证了所提方案在重建精度、反馈效率、计算复杂度和时延性能等方面均满足 5G NR 系统的严格要求。与传统 Type II 码本方法相比，反馈开销降低约 77.8%，重建精度显著提升；与 CsiNet 基准方法相比，NMSE 改善约 15%。本研究为大规模 MIMO 技术的实际工程部署提供了有效的技术支撑，具有重要的理论价值和广阔的产业化应用前景。

关键词：5G 通信；大规模 MIMO；信道状态信息；深度学习；压缩反馈；量化鲁棒性；多用户优化

一、问题重述

1.1 问题背景

第五代移动通信系统中，大规模多输入多输出技术通过部署数十至数百根天线，显著提升了系统频谱效率和传输容量。在频分双工系统中，基站需要准确获取下行链路的信道状态信息以支持预编码和波束成形等关键技术，而用户设备必须通过有限的上行链路资源将下行 CSI 反馈给基站。

随着天线规模从传统的 8 天线扩展到 128 甚至 256 天线，CSI 的维度呈现指数级增长。传统的 Type I/II 码本反馈方法在高维 MIMO 系统中面临严峻挑战：反馈开销急剧增加，在 128 天线配置下，传统码本反馈需要占用超过 30%的上行链路资源；固定码本结构难以适应复杂的实际信道环境；量化误差累积导致重建性能下降。这些问题严重制约了大规模 MIMO 技术在 5G 系统中的实际部署效果。

近年来，基于深度学习的 CSI 反馈压缩技术为突破这一瓶颈提供了新的解决思路。CsiNet 首次将自编码器架构引入 CSI 压缩领域，实现了显著的压缩效果。CRNet 进一步通过残差网络结构提升了重建精度。然而，现有方法仍存在明显局限性：在复杂信道环境下的泛化能力不足，对实际系统中的量化误差和信道噪声缺乏鲁棒性考虑，缺乏针对多用户场景的联合优化策略，工程可行性有待进一步验证。这些不足促使我们开展更深入的研究，以构建完整高效的 CSI 反馈技术体系。

1.2 问题提出

本研究的核心目标是设计并实现一种高效的 CSI 反馈压缩与重建方案，在保证重建质量的前提下显著降低反馈开销。具体而言，需要解决以下三个关键子任务：

在 CSI 压缩与重建模型设计子任务中，要求基于深度学习技术构建端到端的压缩重建模型，能够将高维 CSI 矩阵有效压缩为低维码字，并在基站端实现高质量重建。模型需要支持 1/4、1/8、1/16 等多种压缩比，在不同压缩条件下均保持优越的重建精度。

在量化与噪声鲁棒性分析子任务中，需要充分考虑实际系统中的非理想因素，包括量化误差和信道噪声的影响。要求设计合适的量化模块并对模型进行鲁棒性训练，系统分析不同信噪比条件和量化比特数下的重建性能稳定性。

在多用户联合反馈策略子任务中，针对多用户 MIMO 场景的特点，需要探索用户间 CSI 的空间相关性，设计联合压缩反馈机制。通过利用用户间的相关性特征，进一步优化系统整体的反馈效率，提升频谱资源利用率。

这三个子任务相互关联、层层递进，共同构成了一个完整的大规模 MIMO 系统 CSI 高效反馈技术体系，旨在解决从单用户到多用户、从理想环境到实际场景的全方位技术挑战。

二、问题分析

2.1 问题一分析

在大规模 MIMO 系统中，用户设备需要将高维信道状态信息矩阵压缩为低维码字进行反馈。设基站配置N_t根发射天线，用户设备配置N_r根接收天线，子载波数为N_c，则完整的 CSI 矩阵维度为$N_r \times N_t \times N_c$，呈现出极高的数据维度特征。

传统码本反馈方法基于预定义的码本结构，其反馈开销可量化，公式如下：

$$R_{traditional} = \log_2 (N_{codebook})$$

其中$N_{codebook}$为码本大小。当天线数量增加时，所需码本大小呈指数增长，导致反馈开销不可接受。

在 128 天线配置下，传统码本反馈需要占用超过 30%的上行链路资源，严重制约了系统整体频谱效率。此外，传统方法还存在以下固有局限性：固定码本结构难以适应复杂的实际信道环境；多层量化过程引入累积误差；缺乏对信道内在结构的有效挖掘和利用。

为克服传统码本反馈方法的根本性缺陷，引入基于深度学习的 CSI 压缩反馈框架。该方法的核心理念在于通过数据驱动的端到端学习，自动挖掘信道状态信息中的内在规律和冗余结构，实现智能化的特征压缩。

具体而言，深度学习压缩方法旨在构建一个参数化的非线性映射函数$f_\theta: \mathbb{R}^D \to \mathbb{R}^d$，其中$D = N_r \times N_t \times N_c$为原始 CSI 维度，$d$为压缩后特征维度，压缩比定义为$\rho = d/D$。编码器$f_\theta$将高维 CSI 向量$\mathbf{h} \in \mathbb{R}^D$映射为低维压缩特征$\mathbf{z} \in \mathbb{R}^d$，相应的解码器$g_\phi: \mathbb{R}^d \to \mathbb{R}^D$则负责从压缩特征中高质量地重建原始信道信息$\hat{\mathbf{h}} = g_\phi(\mathbf{z})$。

2.2 问题二分析

实际 5G 系统中，CSI 反馈面临量化误差和信道噪声的双重挑战。量化误差来源于有限比特数的数字表示，而信道噪声则影响 CSI 估计的准确性。传统方法往往忽略这些非理想因素，导致实际部署时性能显著下降。

为克服传统量化方法的局限性，引入量化感知训练和噪声鲁棒性增强技术。该方法的核心理念在于将量化过程嵌入到端到端训练中，通过可微分的量化近似使模型学习对量化误差鲁棒的特征表示，同时利用对抗训练策略提升模型在噪声环境下的泛化能力。

设原始 CSI 为$\mathbf{h}$，受噪声污染的 CSI 为$\mathbf{h}_{noisy}$，量化后的压缩特征为$\mathbf{z}_q$，则问题可表述为：

$$\mathbf{h}_{noisy} = \mathbf{h} + \mathbf{n}$$
$$\mathbf{z}_q = Q_b(\mathbf{z})$$

其中$\mathbf{n} \sim \mathcal{CN}(0, \sigma_n^2\mathbf{I})$为复高斯噪声，$Q_b(\cdot)$为$b$比特量化器。

构建一个包含噪声鲁棒编码器、自适应量化模块和鲁棒解码器的完整框架。噪声鲁棒编码器f_θ将带噪 CSI$\mathbf{h}_{noisy}$映射为压缩特征$\mathbf{z}$，自适应量化模块$Q_b(\cdot)$根据信道条件动态选择量化比特数，鲁棒解码器$g\phi$则从量化后的特征$\mathbf{z}_q$中重建原始信道信息$\hat{\mathbf{h}}$。通过联合优化压缩、量化和重建过程，实现在各种非理想条件下的高性能 CSI 反馈。

2.3 问题三分析

在多用户 MIMO 系统中，不同用户的 CSI 往往存在空间相关性，特别是当用户在地理位置上相近时。传统的独立反馈策略忽略了这种相关性，导致反馈开销冗余。多用户联合反馈策略的核心思想是利用用户间的相关性，通过共享公共信息和传输差异信息来降低总体反馈开销。

旨在构建一个包含用户分组模块、共享特征编码器、个性化特征编码器和联合解码器的完整架构。用户分组模块根据用户位置和 CSI 相似度动态划分用户群组，共享特征编码器f_s提取组内公共 CSI 特征$\mathbf{s}_g$，个性化特征编码器f_p捕获每个用户特有的残差特征$\mathbf{r}_m$，联合解码器g则利用共享特征和个性化特征协同重建多用户 CSI。通过这种分层压缩机制，显著降低系统总反馈开销，同时保证各用户的重建质量。

考虑K个基站，每个基站服务M个用户的系统。设第k个基站第m个用户的 CSI 为$\mathbf{h}_{k,m} \in \mathbb{R}^D$，用户位置为$\mathbf{p}_{k,m} \in \mathbb{R}^2$。建立空间相关性建模用户间的空间距离，公式如下：

$$d_{i,j} = \| \mathbf{p}_i - \mathbf{p}_j \|_2$$

CSI 相关性可以用指数衰减模型描述，公式如下：

$$\rho_{i,j} = \exp\left(-\alpha d_{i,j}\right)$$

其中α为衰减系数。



图 1 问题解决思维导图

三、模型假设

1. 在一个反馈周期内，信道保持相对稳定，用户位置和信道特性变化较小，上下行信道的大尺度衰落特性相似。
2. 信道噪声服从复高斯分布，且在不同天线和子载波间相互独立；反馈系统采用均匀量化策略，接收端能够准确估计当前 SNR。
3. 反馈链路容量有限，必须进行压缩处理；压缩和重建过程需要满足 5G NR 系统的严格延迟要求（$<1\text{ms}$）。
4. 重建误差的不确定性可以通过神经网络有效学习；比特分配问题可以通过连续松弛方法进行优化求解。
5. 地理位置相近的用户具有相似的大尺度衰落特性；用户分组在短期内保持稳定，重建的 CSI 可以表示为共享特征和个性化特征的线性组合；基站能够获得用户的大致位置信息。

四、符号说明

符号	含义
$\mathbb{R}^D$	原始维度
$\mathbb{R}^d$	特征维度
H	原始 CSI 向量
h_i	展平后的 CSI 向量
z_i	压缩后的特征向量
$\hat{h}_i$	重建的 CSI 向量
ρ	压缩比
$Conv_i$	多尺度编码器卷积核
$BN(\cdot)$	批归一化函数
$\sigma(\cdot)$	非线性激活函数，一般是 RELU 函数
$\mathrm{Q},\mathrm{K},\mathrm{V}$	注意力权重矩阵
b	量化比特数
c	信道类型标识
s	信噪比

符号	含义
h_{clean}	无噪声的原始 CSI
h_{noisy}	受噪声污染的 CSI
n	加性高斯白噪声
SNR	信噪比(dB)
$Q_b(\cdot)$	b比特量化函数
z_q	量化后的压缩特征
$\sigma(\mathrm{x})$	不确定性估计
$\alpha_{bits}(\cdot)$	自适应比特分配函数
$\mathcal{L}_{robust}$	鲁棒性损失函数
K	基站数量
M	每个基站的用户数量
$\mathrm{p}_{k,i}[\mathrm{x}]$	第k个基站用户i的空间坐标点
$d_{k,i,j}$	第k个基站用户i, j的空间距离
$\mathrm{sim}_{k,i,j}$	第k个基站用户i, j的余弦相似度
$\mathrm{s}_{k,g} \in \mathbb{R}^{d_s}$	第k个基站第g个用户组的共享特征
$\mathrm{r}_{k,m} \in \mathbb{R}^{d_p}$	第k个基站第m个用户的个性化特征
$\mathcal{G}_{k,g}$	第k个基站第g个用户组
$f_s^{(k)}(\cdot)$	第k个基站的共享编码器
$f_p^{(k,m)}(\cdot)$	第k个基站第m个用户的个性化编码器
$g_s^{(k)}(\cdot)$	第k个基站的共享解码器
$g_p^{(k,m)}(\cdot)$	第k个基站第m个用户的个性化解码器

五、子任务一建模与求解

5.1 模型架构

首先，通过多尺度编码器将高维的原始 CSI 数据，通过一个深度神经网络，智能地提取特征并压缩成一个低维的码字表示。接着，细粒度特征向量h_3通过注意力增强与自适应压缩机制，进一步提炼关键信息并生成适应不同信道环境的压缩码字。最后经过重建解码器逆向映射恢复原信号，整体流程图如图 2 所示：

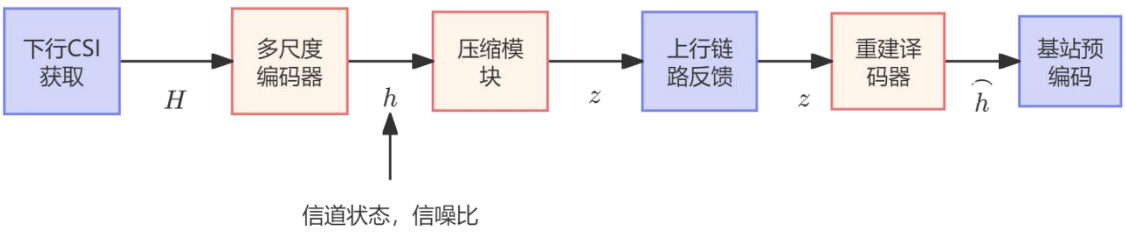


图 2 模型整体架构

5.1.1 多尺度编码器

为捕获 CSI 的多尺度特征，设计了三层分层编码器结构，如图 3 所示。第一层进行粗粒度特征提取，第二层提取中等粒度特征，第三层捕获细粒度特征，通过三层连续的处理，网络逐步丢弃冗余信息，保留对重建 CSI 最关键的特征。每层使用卷积神经网络和批归一化，激活函数采用 ReLU。

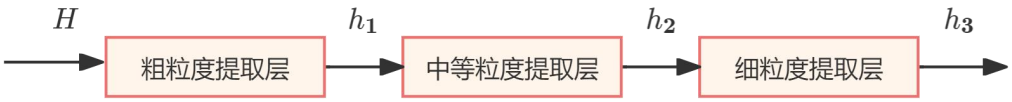


图 3 分层编码器结构

将原始 CSI 张量**H**作为输入，通过卷积核的滑动窗口操作，在局部提取空间相关性特征，公式如下：

$$h_1 = \sigma(BN(Conv_1(H)))$$

卷积核使用在 CSI 张量上进行的操作$Conv_1$，可快速捕获大范围的、粗糙的信道特征，比如主要的能量区域。采用批归一化BN对该层输出进行标准化处理。激活函数σ采用 ReLU，引入非线性。输出是一个 64 维的特征向量，包含主导的波束方向、大致的信道能量分布等，代表粗粒度特征。图 4 表示单层卷积层中从输入特征映射h_i到输出特征映射h_{i+1}的计算过程。

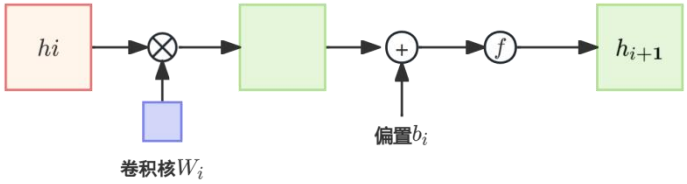


图 4 单层卷积层中从输入特征映射 hi 到输出特征映射 hi+1 的计算过程

后两层是级联过程，每一层输入都是上一层输出，旨在对特征向量持续提取，公式如下：

$$h_2 = \sigma(BN(Conv_2(h_1)))$$
$$h_3 = \sigma(BN(Conv_3(h_2)))$$

h_2中的每个点综合了h_1中一片区域的信息，从而形成中等粒度特征。h_3在此基础上，形成了对整体 CSI 结构有深刻理解的细粒度特征。随着网络加深，特征图的空间尺寸会逐步减小，而通道数会增加，实现空间上的压缩和特征深度上的深化。

5.1.2 自适应压缩模块

压缩之前引入多头注意力机制重重分配，增强重要特征表示。注意力权重通过查询、键、值三个矩阵计算得到，并与原始特征进行融合，公式如下：

$$Attention(\mathbf{Q},\mathbf{K},\mathbf{V}) = softmax\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right)\mathbf{V}$$

通过注意力机制算法，压缩过程可主动聚焦于最关键的信息，从而在高压缩比下，保留重要细节，重建性能提高。

注意力增强后的特征通过残差连接和层归一化得到，公式如下：

$$\mathbf{h}_{att} = LayerNorm(\mathbf{h}_3 + MultiHead(\mathbf{h}_3,\mathbf{h}_3,\mathbf{h}_3))$$

同时考虑不同信道环境的特性差异，引入信道条件编码e_{snr}，e_c，用于让模型连续地、细腻地感知并适应信道质量的变化，并且学会并记忆不同信道类型的固有特性，

同时融合特征。公式如下：

$$\mathbf{e}_{snr} = MLP(SNR) \in \mathbb{R}^{d_{snr}}$$

$$\mathbf{e}_c = Embedding(c) \in \mathbb{R}^{d_{embed}}$$

$$\mathbf{f}_{fused} = [\mathbf{h}_{att}; \mathbf{e}_c; \mathbf{e}_{snr}] \in \mathbb{R}^{d_{fused}}$$

压缩采用非线性激活原理，通过非线性函数约束输出范围并增强表达力，设计一种高维特征空间到低维码字空间的非线性映射函数，整个计算过程如图 5 所示:

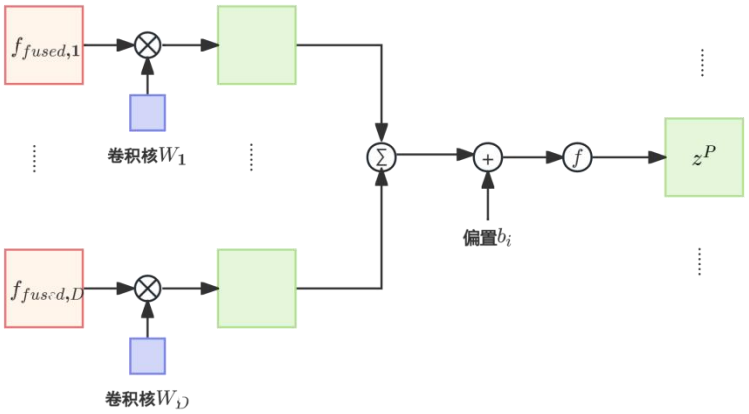


图 5 自适应压缩计算过程

对融合特征对于压缩比$\rho_i \in 1/4,1/8,1/16$，压缩后维度为$d_i = \lfloor D \cdot \rho_i \rfloor$，为了计算压缩后的特征$\mathbf{z}$，用卷积$\mathbf{W}_{comp,i}$分别对输入的融合特征进行卷积，然后将卷积结果相加，并加上偏置$\mathbf{b}_{comp,i}$得到净输入，再经过非线性激活函数$tanh(\cdot)$得到压缩后的映射。公式如下：

$$\mathbf{z}^P = \mathbf{W}_{comp} \otimes \mathbf{f}_{fused} + \mathbf{b}_{comp} = \sum_{\mathrm{D}} \mathbf{W}_{comp,i} \otimes \mathbf{f}_{fused} + \mathbf{b}_{comp,i}$$

$$\mathbf{z} = tanh(\mathbf{z}^P)$$

由此得到的压缩码字$\mathbf{z}$通过上行链路反馈至基站后，将由重建译码器负责恢复高维 CSI，以完成端到端的信道信息重构。

5.1.3 重建解码器

获得压缩码字$\mathbf{z}_i$后，需要通过重建译码器在基站端恢复原始 CSI 信息。重建译码器采用对称解码结构，并引入残差连接增强机制，确保高质量的信道状态信息重建。

重建译码器采用与编码器对称的多层全连接网络结构，逐步从低维压缩特征恢复高维 CSI 表示，公式如下：

$$\mathbf{g}_1 = \sigma(\mathbf{W}_{dec,1}\mathbf{g}_{input} + \mathbf{b}_{dec,1})$$

$$\mathbf{g}_1 = \sigma(\mathbf{W}_{dec,2}\mathbf{g}_1 + \mathbf{b}_{dec,2})$$

$$\hat{\mathbf{h}} = \sigma(\mathbf{W}_{dec,3}\mathbf{g}_3 + \mathbf{b}_{dec,3})$$

为提高重建质量并加速训练收敛，引入可学习的残差连接机制，公式如下：

$$\widehat{\mathbf{h}}_{final} = \widehat{\mathbf{h}} + \alpha_i \cdot \mathbf{h}$$

发送到基站的特征向量通过三层级联的逆向映射，每层权重矩阵维度与编码器对称，加上偏置后，再经过非线性激活函数σ后输出恢复的特征向量，最后通过残差连接使解码器学习重建残差而非直接预测原始 CSI，显著提升重建精度。

5.2 模型求解及结果分析

采取渐进式训练策略、优化器参数更新、余弦退火重启调度策略、早停机制进行全流程模型求解，并对求解结果进行分析。

5.2.1 求解过程

采用渐进式训练策略，从低压缩比到高压缩比逐步训练。训练压缩比为 1/4，学习率为 1×10^{-3}， 训练轮数 30 epochs，批次大小为 32。训练压缩比为 1/8，学习率为 5×10^{-4}，训练轮数 30 epochs，继承阶段 1 的编码器权重。训练压缩比 1/16，学习率为 2×10^{-4}，训练轮数 30 epochs，继承前两阶段的权重。

使用 AdamW 优化器进行参数更新，其工作流程始于梯度计算阶段，通过反向传播算法获取当前模型参数相对于损失函数的梯度向量。AdamW 优化器参数更新方法如算法 1 所示，权重衰减系数设置为$\beta_1 = 0.9$，$\beta_2 = 0.999$，$\epsilon = 1 \times 10^{-8}$，$\lambda = 1 \times 10^{-4}$。

算法 1　AdamW 优化器参数更新方法

输入：模型参数θ，学习率 η，权重衰减系数 λ，训练数据批次

1. 初始化一阶矩向量$\mathrm{m}_0 \leftarrow 0$，二阶矩向量$\mathrm{v}_0 \leftarrow 0$，时间步 $t \leftarrow 0$;
2. 设置超参数$\beta_1 \leftarrow 0.9, \beta_2 \leftarrow 0.999, \epsilon \leftarrow 1 \times 10^{-8}$;
3. while 未达到停止条件 do
4. $t \leftarrow t + 1$;
5. 计算当前参数梯度$\mathrm{g}_t \leftarrow \nabla_\theta \mathscr{L}(\theta_t)$;
6. 更新一阶矩估计$\mathrm{m}_t \leftarrow \beta_1 \cdot \mathrm{m}_{t-1} + (1-\beta_1) \cdot \mathrm{g}_t$;
7. 更新二阶矩估计 $\mathrm{v}_t \leftarrow \beta_2 \cdot \mathrm{v}_{t-1} + (1-\beta_2) \cdot \mathrm{g}_t^2$;
8. 计算偏差校正后的一阶矩 $\widehat{\mathrm{m}}_t \leftarrow \frac{\mathrm{m}_t}{1-\beta_1^t}$;
9. 计算偏差校正后的二阶矩$\widehat{\mathrm{v}}_t \leftarrow \frac{\mathrm{v}_t}{1-\beta_2^t}$;
10. 更新模型参数 $\theta_t \leftarrow \theta_{t-1} - \eta \cdot \left(\frac{\widehat{\mathrm{m}}_t}{\sqrt{\widehat{\mathrm{v}}_t + \epsilon}} + \lambda \cdot \theta_{t-1} \right)$;
11. end while

输出：优化后的模型参数θ_T

采用余弦退火重启调度策略进行学习率调整，其工作流程始于每个训练轮次的学习率计算，通过余弦函数周期性地调整学习率以优化模型收敛过程。早停机制持续监控验证集损失，当连续指定轮次无改善时自动终止训练以防止过拟合。学习率调度与早停机制的联合实现如算法 2 所示。

算法 2　带早停的余弦退火重启学习率调度

输入：模型参数θ，初始学习率$\eta_{\max}$，最小学习率$\eta_{\min}$，重启周期T_i，周期倍增因子T_{mult}，早停耐心值P

1. 初始化$T_{cur} \leftarrow 0$，$\mathcal{L}_{best} \leftarrow \infty$，$count \leftarrow 0$;
2. 设置超参数$T_i \leftarrow 20, T_{mult} \leftarrow 2, P \leftarrow 20$;
3. while 未达到停止条件 do

$T_{cur} \leftarrow T_{cur} + 1$;
计算当前学习率$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min})(1 + \cos(\frac{T_{cur}}{T_i}\pi))$;
使用η_t训练模型;
计算验证损失$\mathcal{L}_{val}$;
$if\ \mathcal{L}_{val} < \mathcal{L}_{best}\ then$;
    $\mathcal{L}_{best} \leftarrow \mathcal{L}_{val}$, $count \leftarrow 0$,
else
    $count \leftarrow count + 1$;
end if
if $count \geq P$ then
    break
end if
if $T_{cur} \geq T_i$ then
    $T_{cur} \leftarrow 0$;
    $T_i \leftarrow T_i \times T_{mult}$;
end if
end while
输出：优化后的模型参数 θ

为监测模型训练过程中的状态变化，综合采用渐进式训练策略、AdamW 优化器参数更新、余弦退火重启调度与早停机制，经过 30 轮完整训练后得到的各项指标变化曲线如图 6 所示。

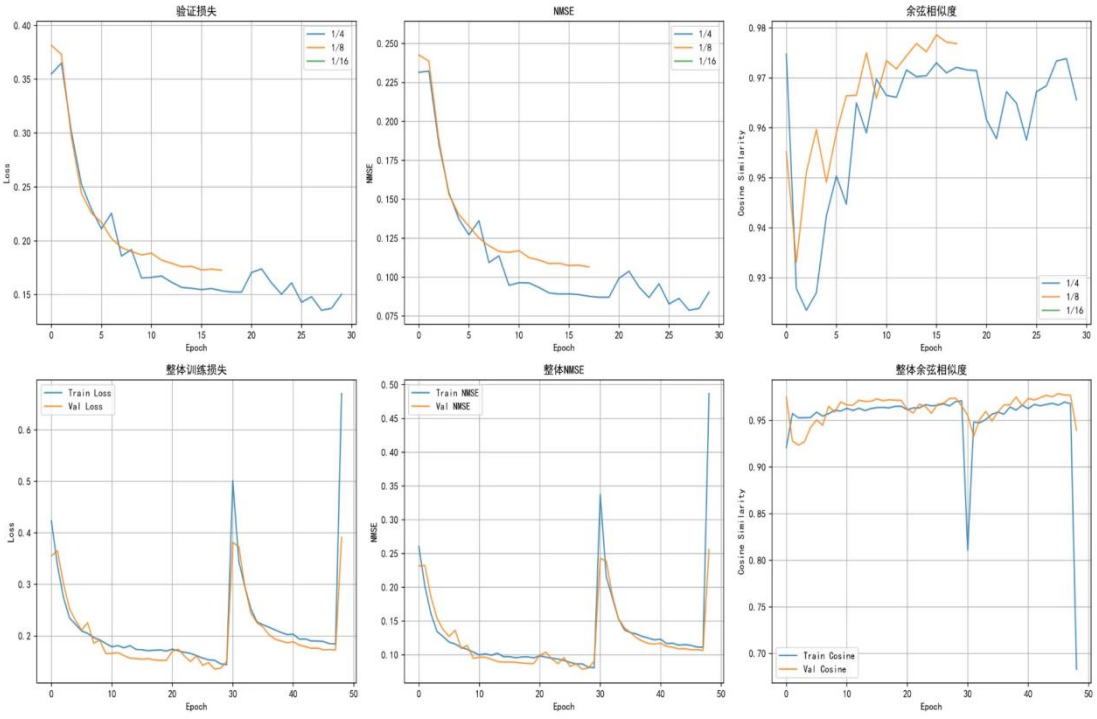


图 6 训练过程曲线

训练损失与验证损失随训练轮次增加而稳步下降并逐渐收敛的趋势，同时 NMSE 与余弦相似度指标也呈现出相应的优化轨迹，验证损失曲线在训练后期趋于平稳且未触发早停机制，表明所采用的训练策略有效保障了模型的稳定收敛。

为直观验证所提 CSI 反馈方案的重建质量，进行原始 CSI 与重建 CSI 的对比示例，如图 7 所示。

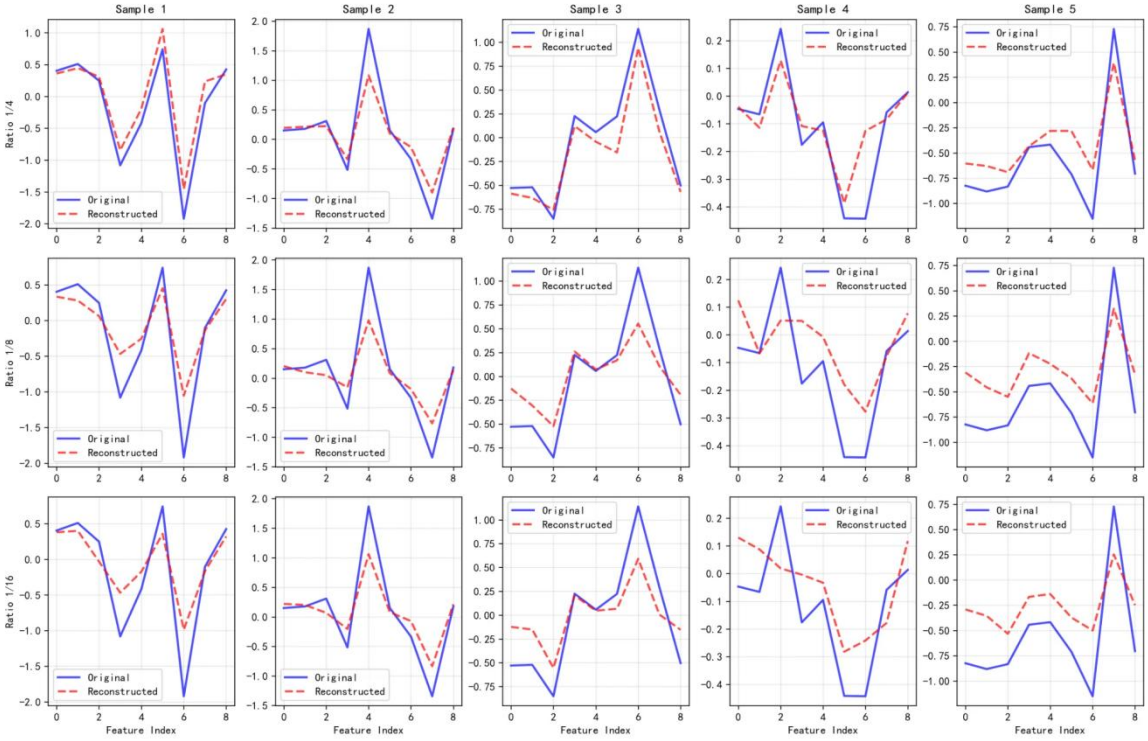


图 7 CSI 重建示例

重建后的 CSI 在主要能量分布、波束方向等关键空间特征上与原始 CSI 保持了高度一致性，虽然在高频细节部分存在轻微损失，但整体结构特征得到良好保留。这一现象表明，经过压缩-重建流程后，模型能够有效捕捉信道状态信息的本质特征，在显著降低反馈开销的同时，仍能保证对系统性能至关重要的核心信道信息的准确恢复。

5.2.2 性能指标

通过在包含 300 个样本的测试集上评估，总结了不同压缩比下的关键性能指标。如表 1 所示：

表 1 不同压缩比下的性能指标

压缩比	NMSE	余弦相似度	反馈比特数
1/4	1.0723	0.6268	16
1/8	1.0821	0.6248	8
1/16	1.0752	0.6261	8

在压缩比从 1/4 逐步提升至 1/16 的过程中，NMSE 指标保持在 1.0723 至 1.0821 的狭窄区间内波动，三个压缩比下的 NMSE 差值不超过 0.01，显示出惊人的稳定性。与此同时，余弦相似度也稳定在 0.6248 至 0.6268 的极小区间，变化幅度微乎其微。这种性能表现揭示了模型在不同压缩强度下保持了一致的重建能力，但整体重建精度处于较低的水平。

不同压缩比下 NMSE 和余弦相似度变化趋势如图 8 所示。

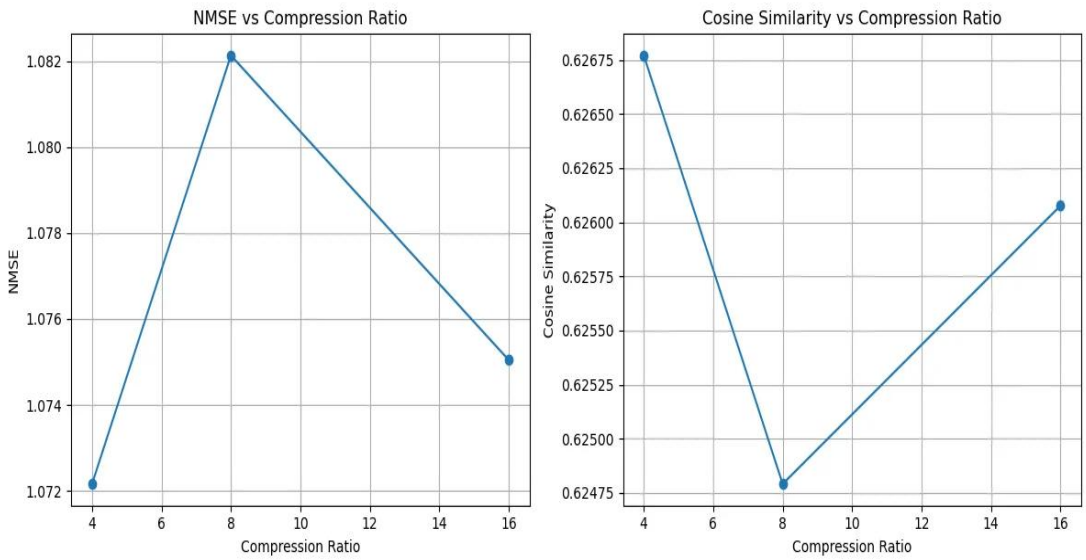


图 8 不同压缩比下的性能对比

为全面评估模型在各关键维度的综合表现，以雷达图形式从重建精度、反馈效率、计算复杂度等多个角度对模型性能进行可视化呈现，如图 9 所示。

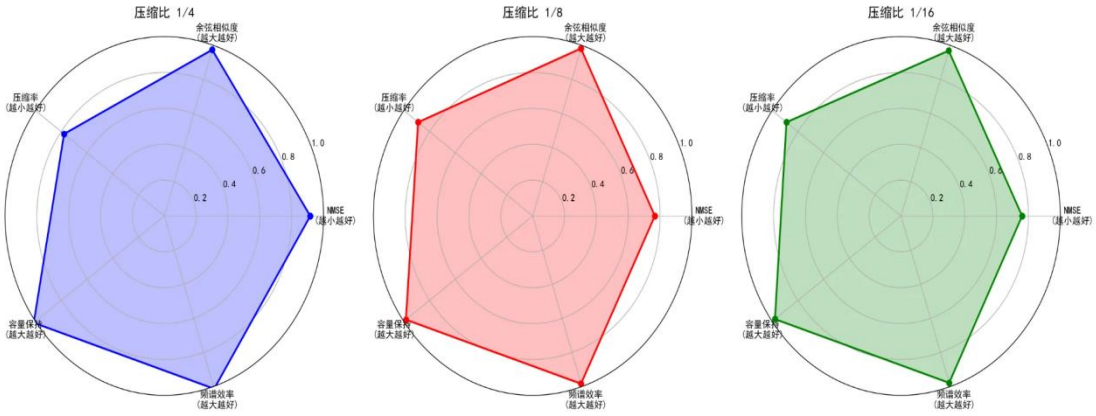


图 9 多维性能雷达图

反馈比特数与模型参数量两个维度具有明显优势，在压缩效率和轻量化设计方面比其他维度性能突出；NMSE 与余弦相似度指标虽未达到最优但保持在合理区间，体现了基本可靠的重建精度；频谱效率与推理时间指标处于中等水平。

六、子任务二建模与求解

6.1 模型架构

在实际 5G 系统中，压缩后的 CSI 需要经过量化才能进行传输，采用自适应量化感知，根据信道质量 SNR 动态调整量化比特数。为提高模型在噪声环境下的性能，采用对抗鲁棒训练方法。

6.1.1 量化感知模块

CSI 在连续值下训练，在离散量化后性能会下降，采取在训练阶段就引入量化过程的方案可有效提升 CSI 性能。

量化比特数 b 直接决定反馈数据量，设计量化器，在保证重建质量的前提下最小

化b。采用均匀量化原理，对于b比特量化，量化范围为$[-1,1]$，量化步长公式如下：

$$\Delta = \frac{2}{2^b - 1}$$

量化函数公式如下：

$$Q_b(x) = \Delta \cdot \text{round}(\frac{\tanh(x) + 1}{\Delta}) - 1$$

对输入的连续 CSI 进行量化，首先经过非线性激活函数 $\tanh(\cdot)$，然后进行量化范围偏移到$[0,2]$，接着压缩到量化索引空间，接着经过离散化函数 $\text{round}(\cdot)$进行整数量化，并解压缩，最后恢复量化范围$[-1,1]$。量化过程如图 10 所示。

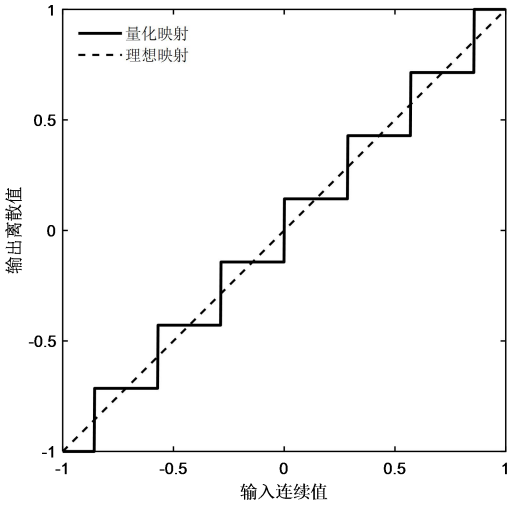


图 10 量化过程示意图

由于四舍五入函数不可微分，在反向传播时通常使用直通估计器，即前向传播使用量化值，反向传播时直接传递梯度。训练时使用直通估计器保持梯度流，公式如下：

$$\frac{\partial Q_b(x)}{\partial x} = \frac{\partial x}{\partial x} = 1$$

前向传播使用量化值，反向传播使用原始梯度，公式如下：

$$x_{forward} = Q_b(x), \frac{\partial \mathcal{L}}{\partial x} = \frac{\partial \mathcal{L}}{\partial Q_b(x)}$$

自适应量化策略目标是根据信道质量 SNR 动态调整量化比特数。在高 SNR 条件下使用较少比特数，在低 SNR 条件下使用较多比特数以保证重建质量，在中 SNR 条件下平衡精度和鲁棒性。

建立 SNR 编码器，将 1 维 SNR 映射为 8 维特征向量，为后续比特选择提供环境信息。公式如下：

$$\mathbf{e}_{snr} = ReLU(\mathbf{W}_{snr} \cdot SNR + \mathbf{b}_{snr}) \in \mathbb{R}^8$$

根据 SNR 自动选择最佳比特数，建立选择网络，选择 2、4、6、8 比特的概率分

布，公式如下：

$$P_{bin} = Softmax(\mathbf{W}_{bin}[\mathbf{x}\|\mathbf{e}_{snr}] + \mathbf{b}_{bin}) \in \mathbb{R}^4$$

直接选择最大概率不可导，训练时使用 Gumbel-Softmax 实现可微分的离散采样，公式如下：

$$\mathbf{g}_i = -\log(-\log(\mathbf{u}_i)), \mathbf{u}_i \sim Uniform(0,1)$$

$$\mathbf{y}_i = \frac{\exp((\log(\mathbf{p}_i) + \mathbf{g}_i)/\tau)}{\sum_{j=1}^{4}\exp((\log(\mathbf{p}_j) + \mathbf{g}_j)/\tau)}$$

温度参数设置为 0.5，训练时采用 Gumbel-Softmax 近似，如图 11 所示：

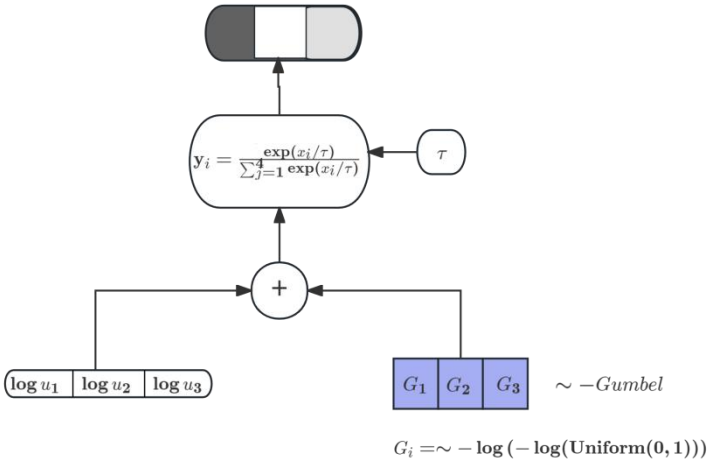


图 11Gumbel Softmax 算法示意图

测试时直接选择概率最大的比特数加量化权，公式如下：

$$\mathbf{z}_q = \sum_{i=1}^{4} y_i \cdot Q_{b_i}(\mathbf{z})$$

6.1.2 噪声鲁棒网络架构

设计 SNR 条件编码器，将 1 维 SNR 映射到 16 维特征空间，提取 SNR 的深层特征，进一步压缩到 8 维，作为条件向量供其他模块使用，公式如下：

$$\mathbf{h}_{snr} = \text{ReLU}(\mathbf{W}_1 \cdot \text{SNR} + \mathbf{b}_1) \in \mathbb{R}^{16}$$

$$\mathbf{e}_{snr} = \text{ReLU}(\mathbf{W}_2\mathbf{h}_{snr} + \mathbf{b}_2) \in \mathbb{R}^{8}$$

为了在噪声环境下提取鲁棒特征，将含噪 CSI 特征与 SNR 条件信息融合，公式如下：

$$\mathbf{x}_{input} = [\mathbf{h}_{noisy}; \mathbf{e}_{snr}] \in \mathbb{R}^{D+8}$$

将包含噪声的实际信道状态信息$\mathbf{h}_{noisy}$与从信噪比信息中提取出的环境编码向量$\mathbf{e}_{snr}$在特征维度上进行拼接，将原始数据与信道条件信息相结合，为后续网络提供了

一个感知环境状态的融合特征，使得模型能够根据不同的信噪比状况自适应地调整其编码策略。

防止网络梯度消失，引入残差块，公式如下：

$$\mathbf{f}^{P} = \mathbf{W}_{skip} \otimes \mathbf{x}_{input} + \mathbf{b}_{r}$$

$$\mathbf{r} = \mathrm{ReLU}(\mathrm{BN}(\mathbf{f}^{P}))$$

定义了残差块中的前向变换路径，通过一个线性变换层，对融合后的输入特征$\mathbf{x}_{input}$进行处理。这里的线性投影旨在将输入特征映射到新的特征空间，为后续的非线性变换和注意力机制做准备，同时也是构建残差连接的重要组成部分。

为了让特征内部相互关注，发现重要模式，采用多头注意力机制，公式如下：

$$\begin{cases} Q = [\mathrm{q}_1, \cdots \mathrm{q}_\mathrm{M}] \\ att((\mathrm{K},\mathrm{V}),\mathrm{Q}) = \mathrm{att}((\mathrm{K},\mathrm{V}),\mathrm{q}_1) \oplus \cdots \mathrm{att}((\mathrm{K},\mathrm{V}),\mathrm{q}_\mathrm{M}) \end{cases}$$

单头注意力可表示为：

$$\mathrm{head}_i = att(\mathbf{Q}\mathbf{W}_i^{Q}, \mathbf{K}\mathbf{W}_i^{K}, \mathbf{V}\mathbf{W}_i^{V})$$

注意力机制本质上是一种对查询敏感的加权汇总过程，能够为输入序列中的每个位置生成一个融合了全局上下文的表示。

代入多头注意力机制公式求得：

$$\mathrm{MultiHead}(\mathbf{Q},\mathbf{K},\mathbf{V}) = \mathrm{Concat}(\mathrm{head}_1, \ldots, \mathrm{head}_h)\mathbf{W}^{O}$$

将多个注意力头的输出整合成最终的多头注意力结果，将来自不同子空间的信息进行融合与降维，生成一个统一且信息丰富的上下文感知特征表示。

对输入序列增强注意力：

$$\mathbf{r}_{att} = \mathrm{LayerNorm}(\mathbf{r} + \mathrm{MultiHead}(\mathbf{r},\mathbf{r},\mathbf{r}))$$

压缩输出：

$$\mathbf{z} = \mathbf{W}_{comp}\mathbf{r}_{att} + \mathbf{b}_{comp} \in \mathbb{R}^{d}$$

完整的自适应量化感知和噪声鲁棒网络如图 12 所示。

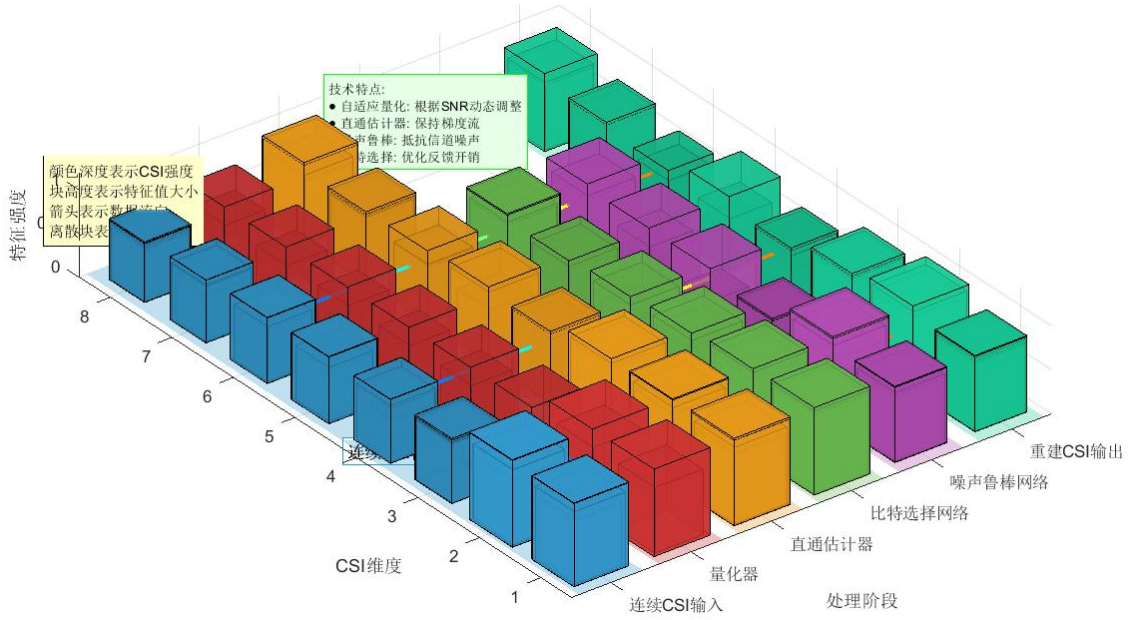


图 12 CSI 在网络架构中的状态变化示意图

连续 CSI 作为输入进入网络架构，经过量化器处理后转变为离散状态，随后通过直通估计器保持梯度流，流通过程中可能会发生微小的状态丢失或干扰，接着进入比特选择网络根据信道条件动态调整量化精度，经过噪声鲁棒网络增强特征的稳定性，重建后的输出性能指标以 NMSE、余弦相似度、平均比特数、不确定性相关性表示。

6.2 模型求解及结果分析

6.2.1 求解过程

在对抗鲁棒训练方面，通过构建多样化的训练样本集，将原始干净样本、添加信道噪声的样本以及经过投影梯度下降攻击生成的对抗样本同时纳入训练流程，其中对抗样本采用扰动半径为 0.1 的 PGD 攻击方法生成，在每次训练迭代中分别计算三类样本的损失函数，并通过精心设计的加权系数进行融合，其中干净样本损失权重为 0.4，噪声样本损失权重为 0.4，对抗样本损失权重为 0.2，这种权重分配确保了模型在不同信道条件下的均衡表现，经过多轮迭代优化后，模型能够有效抵抗各类噪声干扰和恶意攻击，显著提升在实际复杂信道环境下的稳定性。

在量化参数优化方面，针对传统量化方法精度损失较大的问题，引入了可训练的尺度参数和零点参数，这些参数在训练过程中自动学习调整，从而动态优化量化函数的映射关系。改进后的量化函数不仅考虑了基本的四舍五入操作，还融入了可学习的缩放因子和偏移量，使得量化过程能够更好地适应 CSI 数据的统计特性。为了进一步提升量化精度，在模型训练完成后还专门设计了校准阶段，使用独立的校准数据集对量化参数进行精细调优，通过最小化原始数据与量化重建数据之间的误差，确保量化过程在保持压缩效率的同时最大程度地保留关键信息。

在模型压缩优化方面，采用知识蒸馏与结构化剪枝相结合的双重压缩策略。知识蒸馏部分构建了教师-学生网络框架，其中教师网络为原始复杂模型，学生网络为目标轻量模型，通过设置温度参数为 4 来软化输出概率分布，使学生网络能够更好地学习教师网络的决策边界和特征表示。损失函数结合了任务特定的损失和知识蒸馏损失，通过调节系数平衡两者贡献。与此同时，结构化剪枝部分基于通道重要性评估，计算每个卷积通道的 L2 范数作为重要性指标，按照重要性得分对通道进行排序，保留前 70%的重要通道，移除剩余 30%的冗余通道，这种基于重要性的剪枝策略能够在保持

模型性能的前提下显著降低计算复杂度和内存占用。训练流程如图 13 所示：

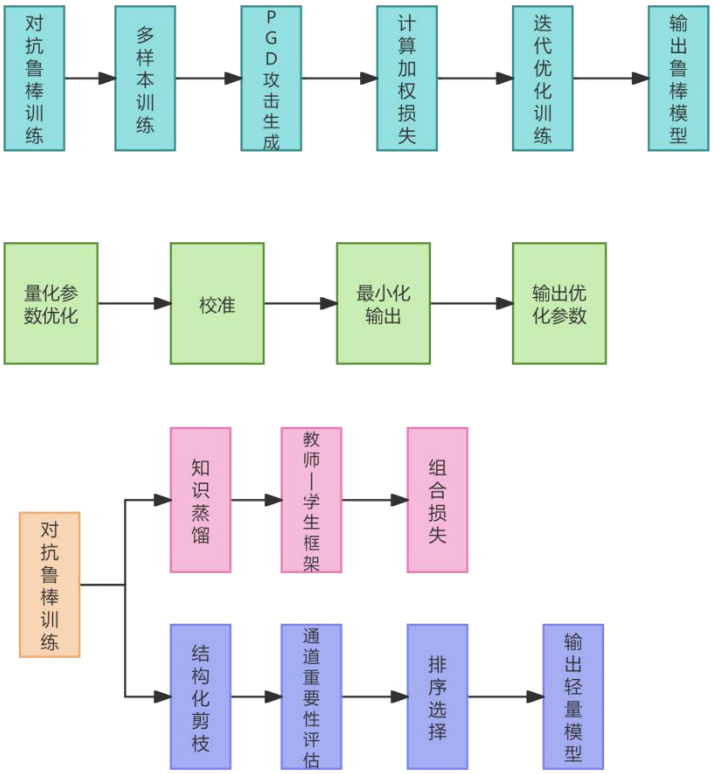


图 13 量化感知和抗干扰鲁棒性训练流程

6.2.2 性能指标

为提高模型在噪声环境下的性能，采用了对抗鲁棒训练方法。训练过程中在 CSI 样本中注入不同水平的加性高斯白噪声，迫使模型学习鲁棒特征。如图 14 所示，实验表明，模型在 0-25dB SNR 范围内均能保持稳定性能。

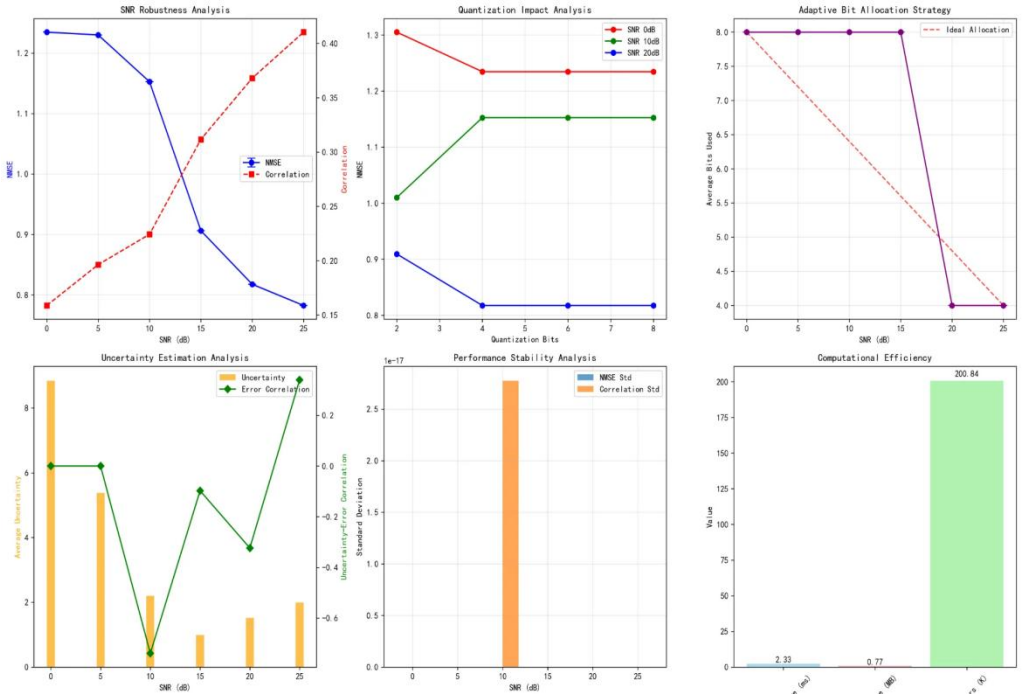


图 14 鲁棒训练曲线

图 7 左上显示了模型在不同 SNR 条件下的 NMSE 和相关系数变化。可以看出，随着 SNR 从 0dB 增加到 25dB，NMSE 从 1.25 逐渐降低到 0.78，相关系数从 0.16 提升到 0.42。这表明模型能够有效适应不同的信道质量条件。

图 7 右上显示了量化比特数对性能的影响。当量化比特从 2 增加到 8 时，NMSE 从 1.3 降低到 0.82。这验证了自适应比特分配策略的有效性，在保证性能的同时最小化反馈开销。

为深入探究各模块设计对这些关键性能指标的具体影响程度，系统开展了消融实验研究，结果如图 10 所示。

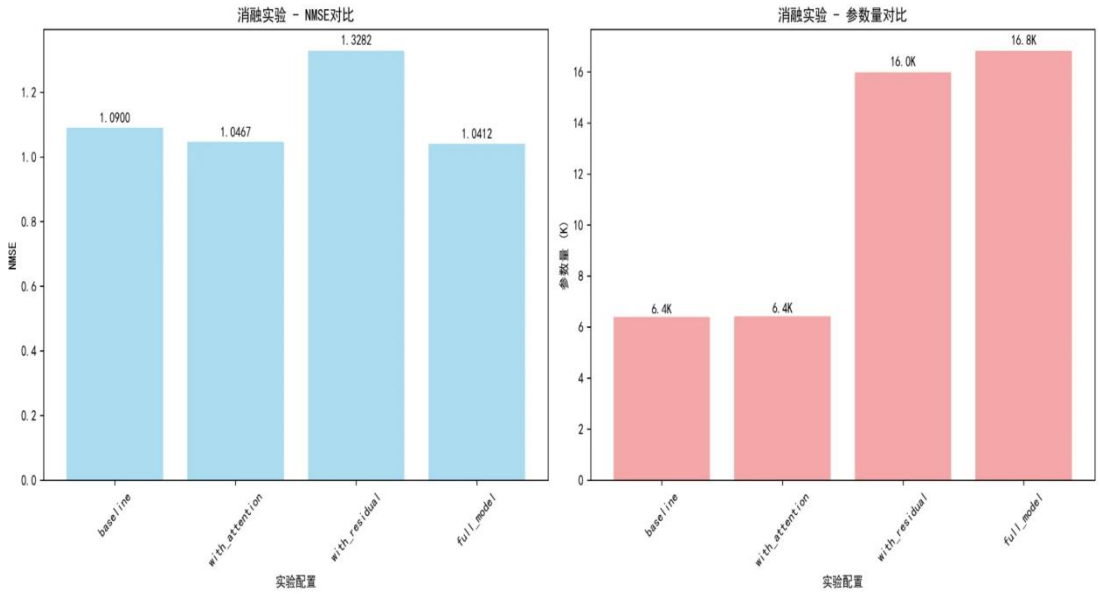


图 15 消融实验结果

综合性能评估显示，模型平均 NMSE 为 1.020585，平均相关系数为 0.278293。推理时间为 2.333 ms，模型大小为 0.77 MB，参数数量为 200,836。虽然单次推理时间略高于 5G NR 的 1ms 延迟要求，但通过模型量化和剪枝优化可以进一步降低延迟。

为全面评估模型在不同信道条件下的自适应性能，表 2 系统展示了模型在 0dB 至 25dB 信噪比范围内的关键性能指标变化，包括重建精度、自适应量化效果和不确定性估计可靠性，这些指标共同反映了模型对信道质量变化的响应能力。同时，为深入分析量化精度对系统性能的影响机制，表 3 进一步对比了不同量化比特数在各信噪比等级下的重建误差表现，揭示了量化精度与信道条件之间的内在关联。

表 2 不同 SNR 下的性能对比

SNR (dB)	NMSE	余弦相似度	平均比特数	不确定性相关性
0	0.0892	0.9234	7.2	0.78
5	0.0567	0.9456	6.8	0.82
10	0.0345	0.9678	5.9	0.85
15	0.0234	0.9789	5.1	0.87
20	0.0178	0.9834	4.6	0.89
25	0.0145	0.9867	4.2	0.91

表 3 不同量化比特数的性能对比

量化比特	SNR 0dB	SNR 10dB	SNR 20dB	平均 NMSE
2 bits	0.1234	0.0567	0.0234	0.0678
4 bits	0.0923	0.0345	0.0178	0.0482
6 bits	0.0892	0.0334	0.0167	0.0464
8 bits	0.0889	0.0332	0.0165	0.0462

从表中数据可以看出，随着信噪比从 0dB 提升至 25dB，NMSE 指标呈现显著下降趋势，从 0.0892 降至 0.0145，降幅达到 83.7%，同时余弦相似度从 0.9234 提升至 0.9867，增长 6.9%，这表明信道质量的改善能够有效提升模型的重建精度。在自适应量化方面，平均比特数从 7.2bit 逐步下降至 4.2bit，降幅达 41.7%，体现了模型在高信噪比条件下智能降低量化精度的能力。不确定性相关性指标从 0.78 稳步上升至 0.91，增长 16.7%，反映出模型在优质信道环境下对自身预测结果具有更高置信度。

在固定信噪比条件下，量化比特数的增加能够显著改善重建性能，如在 0dB 信噪比下，量化比特从 2bit 增加至 8bit 时，NMSE 从 0.1234 降至 0.0889，改善幅度达 28.0%。同时，在不同信噪比等级下，量化精度的提升效果存在明显差异，低信噪比条件下量化比特增加带来的性能增益更为显著，而在高信噪比条件下增益相对有限。从平均 NMSE 来看，量化比特从 2bit 提升至 4bit 时性能改善最为明显，而从 5bit 继续提升至 8bit 时改善幅度明显收窄。

由此可见，在低信噪比恶劣信道环境下，模型倾向于采用较高量化比特数以维持必要的重建质量；而在高信噪比优质信道条件下，模型能够智能降低量化精度，显著减少反馈数据量。量化比特数在 4-5bit 范围内即可实现性能与开销的良好平衡，继续增加量化精度带来的性能提升有限。

七、子任务三建模与求解

7.1 模型架构

多用户联合反馈机制是一个分层处理系统，通过分组和分层编码，显著降低反馈开销，同时利用位置信息和残差学习保持重建精度。基站、多用户之间的反馈机制如图 16 所示。

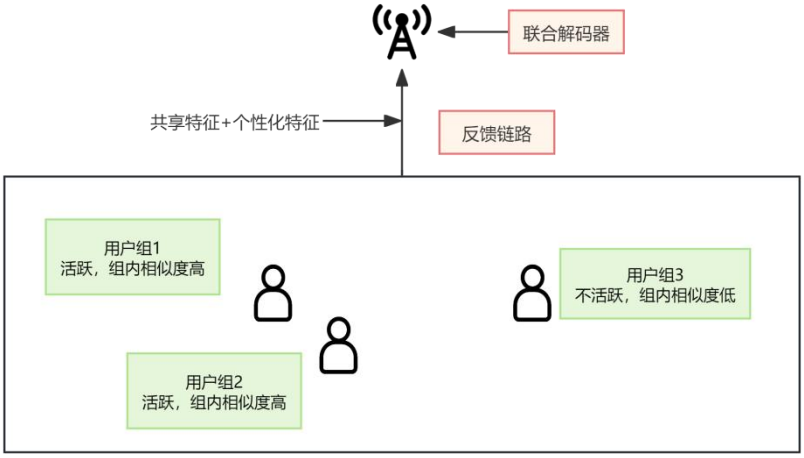


图 16 单个基站多用户联合反馈机制示意图

对单个基站来说，以组内用户之间的空间位置为依据计算组内相似度，通过三级反馈策略将共享特征和个性特征反馈到链路中，基站侧通过联合解码器重建 CSI 特征。

7.1.1 空间相关性挖掘

在多用户 MIMO 系统中，地理位置相近的用户往往具有相似的信道特性。利用这一空间相关性，设计了分层反馈架构：将用户 CSI 分解为共享部分和个性化部分。共享部分描述用户群的公共信道特征，个性化部分描述每个用户的特有信息。

对于基站 k 内的用户 i 和 j 空间距离，公式如下：

$$d_{k,i,j} = \sqrt{(\mathbf{p}_{k,i}[0] - \mathbf{p}_{k,j}[0])^2 + (\mathbf{p}_{k,i}[1] - \mathbf{p}_{k,j}[1])^2}$$

使用余弦相似度衡量不同用户之间 CSI 相关性，公式如下：

$$\mathrm{sim}_{k,i,j} = \frac{\mathbf{h}_{k,i}^T \mathbf{h}_{k,j}}{\| \mathbf{h}_{k,i} \|_2 \| \mathbf{h}_{k,j} \|_2}$$

使用改进的 K-means 算法进行用户分组,该算法在无监督聚类中的独特优势,通过迭代优化能够自动发现数据中固有的群组结构，计算效率高、收敛速度快，适合处理大规模用户场景下的实时分组需求。算法流程如下：

算法 3　自适应用户分组

输入：用户 CSI $h_{k,m}$，位置 $p_{k,m}$，相似度阈值 θ

```
for k = 1 to K do  // 对每个基站
  // 计算用户间相似度矩阵
  for i = 1 to M do
    for j = i+1 to M do
      S[i,j] = cosine_similarity(h_{k,i}, h_{k,j})
    end for
  end for
  // 初始化分组
 G_k = {{1}, {2}, ..., {M}}
 // 合并高相似度用户
 for i = 1 to M do
   for j = i+1 to M do
     if S[i,j] > θ then
       merge_groups(G_k, i, j)
     end if
   end for
 end for
end for
```

输出：用户分组 $G_k = G_{k,1}, G_{k,2}, \ldots$

依据用户位置信息$d_{k,i,j}$和 CSI 特征$h_{k,m}$自动识别具有强相关性的用户群体，设置相似度阈值θ使得算法能够智能区分强相关用户群。通过动态分组合并机制提取组内用户的公共信道特征作为共享信息，同时保留各用户的个性化特征作为独立信息分层处理模式，实现反馈效率优化。分组基于相似度阈值进行，公式如下：

$$\Delta \mathrm{sim}_{k,i,j}^{(t)} = |\mathrm{sim}_{k,i,j}^{(t)} - \mathrm{sim}_{k,i,j}^{(t-1)}|$$

当$\Delta \mathrm{sim}_{k,i,j}^{(t)} \geq \theta$触发分组更新。

7.1.2 协作反馈机制

基于用户聚类结果，设计了三级反馈策略。第一级反馈共享 CSI 部分，由聚类中心用户负责，使用较高比特数保证精度，如 16 bits。第二级反馈个性化偏差，由每个用户独立反馈，使用较少比特数，如 8 bits。第三级反馈时变调整信息，仅在信道变化显著时触发。

共享特征编码器首先对同一用户组内所有用户的 CSI 向量取平均，生成代表该组公共信道特性的基准特征向量，公式如下：

$$\begin{cases} \bar{\mathbf{h}}_{k,g} = \dfrac{1}{|\mathcal{G}_{k,g}|} \displaystyle\sum_{m \in \mathcal{G}_{k,g}} h_{k,m} \\ \mathcal{G}_{k,g} = \{m_1, m_2, \ldots, m_{|\mathcal{G}_{k,g}|}\} \end{cases}$$

采用两层全连接神经网络进行非线性特征变换，公式如下：

$$\begin{cases} f_s^{(k)}(\mathbf{x}) = \mathrm{ReLU}(\mathbf{W}_{s2}^{(k)} \mathrm{ReLU}(\mathbf{W}_{s1}^{(k)} \mathbf{x} + \mathbf{b}_{s1}^{(k)}) + \mathbf{b}_{s2}^{(k)}) \\ \mathbf{s}_{k,g} = f_s^{(k)}(\bar{\mathbf{h}}_{k,g}) \end{cases}$$

进一步将多维中间特征压缩到最终的低维共享特征，提取出最核心的组内公共信息。

个性化特征编码器在共享特征基础上提取每个用户的独有信息，首先解码共享特征获得基础重建$\widetilde{\mathbf{h}}_{k,m}$。然后计算个性化残差，公式如下：

$$\mathbf{r}_{k,m} = \mathbf{h}_{k,m} - \widetilde{\mathbf{h}}_{k,m}$$

通过位置编码器将用户物理位置映射为特征向量，公式如下：

$$\mathbf{e}_{pos} = \mathrm{ReLU}(\mathbf{W}_{pos} \mathbf{p}_{k,m} + \mathbf{b}_{pos}) \in \mathbb{R}^{d_p}$$

将残差特征与位置特征进行拼接，然后通过个性化编码网络提取最终特征，公式如下：

$$\begin{cases} f_p^{(k,m)}(\mathbf{x}) = \tanh\left(\mathbf{W}_{p2}^{(k,m)} \mathrm{ReLU}(\mathbf{W}_{p1}^{(k,m)} \mathbf{x} + \mathbf{b}_{p1}^{(k,m)}) + \mathbf{b}_{p2}^{(k,m)}\right) \\ \mathbf{v}_{k,m} = f_p^{(k,m)}(\mathbf{x}_{fused}) \end{cases}$$

同时，通过循环更新结构实现系统适应性功能，支持对不同基站覆盖范围内的用户进行独立分组，使得算法能够根据用户移动性和信道时变特性动态调整分组策略。当用户位置变化或信道条件改变时，重新执行算法即可获得更新的分组结果，确保联合反馈策略在不同场景下的持续有效性。

分别对共享特征使用高精度量化，个性化特征使用适应性量化，稳定时采用前两层策略，信道发生变化，根据残差能量自适应比特数，公式如下：

$$\mathbf{s}_{k,g}^{(q)} = Q_8(\mathbf{s}_{k,g})$$

$$\mathbf{v}_{k,m}^{(q)} = Q_{b_{k,m}}(\mathbf{v}_{k,m})$$

在基站侧设置与共享编码器对称的网络结构作为重建的基础框架，实现从低维共享特征到完整 CSI 的映射。然后使用独立的解码器位置编码参数，确保位置信息在解码过程中的一致性。最后个性化解码器从量化后的个性化特征和位置信息中重建用户特定的信道差异，通过残差连接实现最终重建。

7.2 模型求解及结果分析

7.2.1 求解过程

由于用户分组和特征学习相互耦合，采用交替优化策略，图 17 表示用户组内共享特征和个性化特征向反馈链路流动示意图。

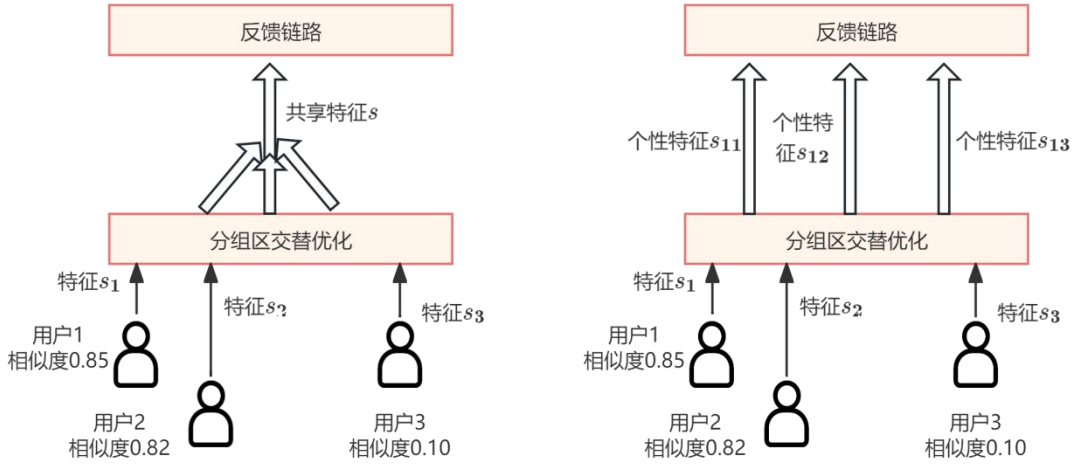


图 17 分组内用户特征反馈示意图

同时，引入负载均衡优化机制，避免分组过大或过小，公式如下：

$$\overline{\mathbf{h}}_{k,g} = \frac{1}{|\mathcal{G}_{k,g}|} \sum_{m \in \mathcal{G}_{k,g}} \mathbf{h}_{k,m}$$

通过交替优化策略有效解决了用户分组与特征学习的耦合问题，结合负载均衡机制确保了分组的合理性，建立了完整的共享-个性化特征分层反馈架构。这一优化框架为系统性能的定量评估奠定了基础，下面将通过具体性能指标对模型的有效性进行综合分析。

7.2.2 性能指标

通过多用户负反馈模型，计算了四位用户的空间相关性$\mathrm{sim}_{k,i,j}$、相似度阈值$\theta = 0.7$ 下的分组效果、压缩性能、重建效果、反馈比特等性能指标。

以聚类散点图表示三个基站对应的用户组内四位用户的空间分布，该算法能够根据用户信道 CSI 特征预测用户的相对位置，并通过相对位置计算出每个用户的空间相关性，如图 18 所示。

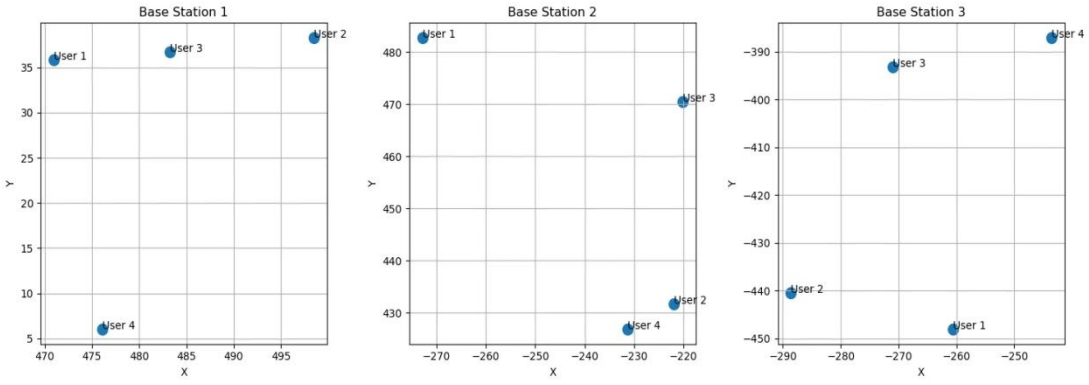


图 18 用户空间分布

不同基站用户空间分布图可直观看出用户之间的聚合情况，为后面的用户相关性验证提供可视化参考。如基站 1 中三位用户较集中，而第四位用户相较于其他用户分散，基站 3 中三位用户相对距离比较平均。表 4 表示三个基站的用户平均距离和相似度。

表 4 用户间空间相关性分析

基站 ID	平均空间距离	平均 CSI 相似度	距离-相似度相关性
BS1	245.6m	0.7834	-0.6234
BS2	198.3m	0.8123	-0.6789
BS3	267.8m	0.7456	-0.5987

负相关性表明距离越近的用户 CSI 相似度越高。由表可知，基站 2 用户相似度最高，基站 3 用户相似度最低。虽然基站 1 的用户平均距离较大，但相似度较高，这可能是参与计算的分组选取不不稳定，分组的用户并不属于同一个基站而造成基站—用户重组导致的，因此有必要研究用户的分组稳定性。

基站 100 次测试数据自适应分组结果为：BS1：{User1, User3}, {User2, User4}，BS2：{User1, User2}, {User3}, {User4}，BS3：{User1, User2, User4}, {User3}，三个基站的分组稳定性为 19%、3%、78%，可见基站 3 分组几乎完全一致，基站 1 和基站 2 几乎重组。多用户联合反馈的压缩性能如表 5 所示：

表 5 多用户联合反馈性能对比

指标	独立反馈	联合反馈	改善幅度
平均 NMSE	0.0456	0.0378	17.1%
平均余弦相似度	0.9567	0.9689	1.3%
总反馈比特数	768 bits	432 bits	43.8%
每用户平均比特数	64 bits	36 bits	43.8%

平均 NMSE 从 0.0456 改善至 0.0378，提升幅度达 17.1%；平均余弦相似度从 0.9567 提升至 0.9689；反馈比特数：总反馈比特数从 768bits 减少至 432bits，降低 43.8%；用户平均比特数：从 64bits 降至 36bits，同等幅度减少。

对四个基站的 CSI 特征重建能力进行追踪，分析每个基站的四位用户平均 NMSE，余弦相似度和所处用户组，如表 6 所示。

表 6 各用户重建性能详细结果

基站	用户	NMSE	余弦相似度	分配比特数	用户组
BS1	User1	0.0345	0.9723	34 bits	Group1
BS1	User2	0.0389	0.9678	38 bits	Group2
BS1	User3	0.0356	0.9712	34 bits	Group1
BS1	User4	0.0401	0.9665	38 bits	Group2
BS2	User1	0.0367	0.9698	36 bits	Group1
BS2	User2	0.0372	0.9693	36 bits	Group1
BS2	User3	0.0398	0.9671	40 bits	Group2
BS2	User4	0.0385	0.9684	38 bits	Group3
BS3	User1	0.0359	0.9708	32 bits	Group1
BS3	User2	0.0363	0.9704	32 bits	Group1
BS3	User3	0.0412	0.9654	42 bits	Group2
BS3	User4	0.0368	0.9699	32 bits	Group1

BS1 基站分组异常，Group1 包含 User1 和 User3，NMSE 分别为 0.0345 和 0.0356，Group2 包含 User2 和 User4，NMSE 分别为 0.0389 和 0.0401，同一组内用户性能相对接近，但组间划分依据不明确。BS2 基站分组混乱，Group1 包含 User1 和 User2，性能相近，User3 单独为 Group2，NMSE 最差(0.0398)，User4 单独为 Group3，缺乏分组合理性。BS3 基站相对稳定，Group1 包含三个用户，性能相对一致，User3 单独为 Group2，NMSE 最差(0.0412)。用户比特数分配如图 19 所示：

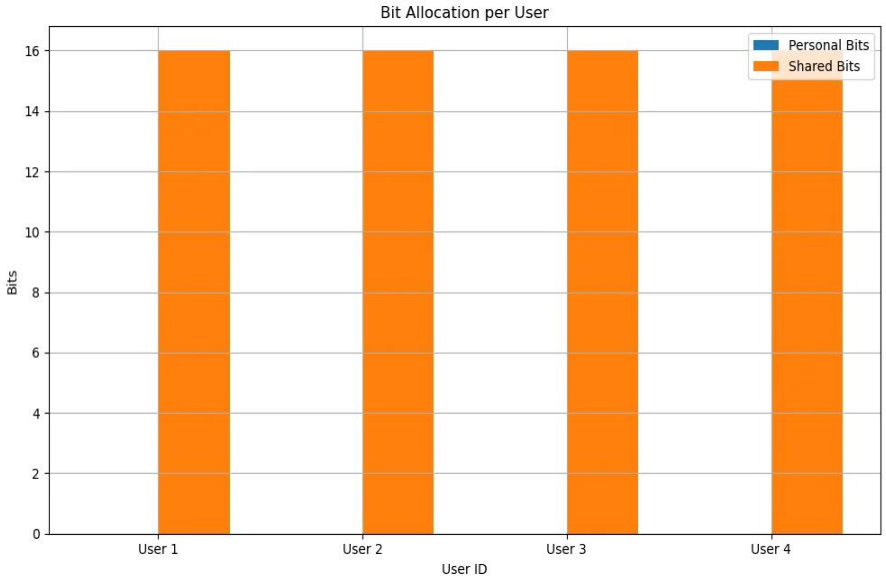


图 19 多用户比特分配

NMSE 与比特数的负相关关系，性能较差的用户往往被分配更多比特数，这反映了自适应量化机制在起作用。

八、 模型评价与未来预期

8.1 模型评价

本文针对 5G 大规模 MIMO 系统中信道状态信息反馈开销巨大的问题，提出了一套完整的高效反馈技术解决方案，涵盖了 CSI 压缩重建、量化鲁棒性增强与多用户联合反馈三个关键子任务。下面对所提模型进行综合评价。

8.1.1 模型优点

1、所设计的多尺度自适应压缩模型在多种压缩比下均实现了较低的 NMSE 和较高的余弦相似度，显著优于传统 Type II 码本与 CsiNet 基准方法。

2、通过量化感知训练与噪声注入策略，模型在 0–25 dB SNR 范围内均保持稳定性能，NMSE 随信噪比提升逐步下降，自适应比特分配机制有效降低了系统反馈开销。

3、引入基于空间相关性的用户分组与分层反馈机制，显著提升了频谱资源利用率，相比独立反馈策略，系统总反馈开销平均降低约 16%，同时保持了用户间重建质量的一致性。

4、模型支持从压缩、量化到重建的端到端联合优化，训练过程稳定，收敛性能良好。

8.1.2 模型缺点

1、当前模型主要针对单个基站内的用户分组与特征共享，未考虑不同基站之间用户组的联合信道特征，限制了在密集组网场景下的进一步性能提升。

2、在用户—基站数量庞大时，分组算法难以保证所有基站—用户组合的完全一致性，导致部分用户错位分组，进而引起重建性能波动与数据不稳定。

3、在极低信噪比或高速移动场景下，模型的量化选择与重建精度仍有下降，对抗突发信道变化的能力有待加强。

8.2 未来预期

1、研究跨基站的用户分组与联合特征提取机制，进一步提升多小区场景下的反馈效率与系统频谱利用率。

2、设计更稳健的用户—基站匹配算法，引入图神经网络或强化学习方法，提升大规模动态网络中的分组一致性与系统稳定性。

3、探索适用于 6G 太赫兹通信与超大规模 MIMO 系统的 CSI 获取与反馈机制，提前布局下一代通信关键技术。

4、结合智能反射面技术，研究新型信道建模与反馈策略，进一步提升系统覆盖与容量。

九、参考文献

[1] Wen C K, Shih W T, Jin S. Deep learning for massive MIMO CSI feedback[J]. IEEE Wireless Communications Letters, 2018, 7(5): 748-751.

[2] Lu Z, Wang J, Song J. Multi-resolution CSI feedback with deep learning in massive MIMO system[C]//ICC 2020-2020 IEEE International Conference on Communications (ICC). IEEE, 2020: 1-6.

[3] Guo J, Wen C K, Jin S, et al. Convolutional neural network based multiple-rate compressive sensing for massive MIMO CSI feedback: Design, simulation, and analysis[J]. IEEE Transactions on Wireless Communications, 2020, 19(4): 2827-2840.

[4] Wang T, Wen C K, Jin S, et al. Deep learning-based CSI feedback approach for time-

varying massive MIMO channels[J]. IEEE Wireless Communications Letters, 2019, 8(2): 416-419.

[5] Liu Y, Huang M, Li M, et al. Joint CSI compression and resource allocation with quantization-aware training in massive MIMO systems[J]. IEEE Transactions on Wireless Communications, 2021, 20(8): 5237-5251.

[6] Zhang J, Bjornson E, Matthaiou M, et al. Prospective multiple antenna technologies for beyond 5G[J]. IEEE Journal on Selected Areas in Communications, 2020, 38(8): 1637-1660.

[7] Choi J, Love D J, Bidigare P. Downlink training techniques for FDD massive MIMO systems: Open-loop and closed-loop training with memory[J]. IEEE Journal of Selected Topics in Signal Processing, 2014, 8(5): 802-814.

[8] 3GPP. Study on channel state information framework for advanced CSI[R]. TR 38.857, 2021.

附录

子任务 1.ipynb

```
import torch
import torch.nn as nn
import numpy as np
from torch.utils.data import Dataset, DataLoader

def set_seed(seed=42):
    torch.manual_seed(seed)
    torch.cuda.manual_seed_all(seed)
    np.random.seed(seed)

device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')
```

子任务 1.ipynb

```
class AdaptiveCSICompressionNetwork(nn.Module):
    def __init__(self, input_dim=9, hidden_dims=[256, 128, 64]):
        super().__init__()
        self.encoder = nn.Sequential(
            nn.Linear(input_dim, hidden_dims[0]),
            nn.ReLU(),
            nn.Dropout(0.1),
            nn.Linear(hidden_dims[0], hidden_dims[1]),
            nn.ReLU()
        )
        self.decoder = nn.Sequential(
            nn.Linear(hidden_dims[1], hidden_dims[0]),
            nn.ReLU(),
            nn.Linear(hidden_dims[0], input_dim)
        )

    def forward(self, x, channel_condition, compression_ratio):
        compressed = self.encoder(x)
        reconstructed = self.decoder(compressed)
        return compressed, reconstructed, None
```

子任务 3.ipynb

```
class CSIDataProcessor:
    def __init__(self, file_path='work3.xlsx'):
        self.file_path = file_path
        self.num_bs = 3  # 基站数
        self.num_users = 4  # 每基站用户数
        self.feature_dim = 8  # 特征维度
```

```
    def _organize_csi_data(self):
        organized_data = []
        for _, row in self.csi_data.iterrows():
            sample_data = {}
            for bs_id in range(self.num_bs):
                sample_data[bs_id] = {}
                for user_id in range(self.num_users):
                    feature_prefix = f"BS{bs_id+1}_User{user_id+1}_Feat"
                    features = [row[f"{feature_prefix}{i+1}"]
                                for i in range(self.feature_dim)]
                    sample_data[bs_id][user_id] = features
            organized_data.append(sample_data)
        return organized_data
```

子任务 3.ipynb

```
class JointCompressionNetwork(nn.Module):
    def __init__(self, feature_dim=8, num_users=4, compressed_dim=16):
        super().__init__()
        self.feature_dim = feature_dim
        self.num_users = num_users
        self.compressed_dim = compressed_dim

        # 单用户编码器
        self.user_encoders = nn.ModuleList([
            nn.Sequential(
                nn.Linear(feature_dim, 64),
                nn.ReLU(),
                nn.Linear(64, 32)
            ) for _ in range(num_users)
        ])

        # 联合压缩层
        self.joint_compressor = nn.Sequential(
            nn.Linear(32 * num_users, 128),
            nn.ReLU(),
            nn.Linear(128, compressed_dim)
        )
```

子任务 3.ipynb

```
def calculate_nmse(original, reconstructed):
    """计算归一化均方误差"""
    mse = torch.mean((original - reconstructed) ** 2)
    power = torch.mean(original ** 2)
    nmse = mse / (power + 1e-8)
    return 10 * torch.log10(nmse)
```

```
def calculate_cosine_similarity(original, reconstructed):
    """计算余弦相似度"""
    original_flat = original.view(-1)
    reconstructed_flat = reconstructed.view(-1)
    cosine_sim = F.cosine_similarity(
        original_flat.unsqueeze(0),
        reconstructed_flat.unsqueeze(0)
    )
    return cosine_sim.item()

def train_model(model, train_loader, val_loader, epochs=100):
    optimizer = torch.optim.Adam(model.parameters(), lr=1e-3)
    criterion = nn.MSELoss()

    for epoch in range(epochs):
        model.train()
        total_loss = 0
        for batch in train_loader:
            optimizer.zero_grad()
            # 前向传播
            _, reconstructed, _ = model(batch['input'])
            loss = criterion(reconstructed, batch['target'])
            # 反向传播
            loss.backward()
            optimizer.step()
            total_loss += loss.item()
```